# 机器学习第三次实验实验报告

# 实验要求

在这个练习中,需要用 Python 实现 LeNet5 来完成对 MNIST 数据集中 0-9 10 个手写数字的分类。代码只能使用 python 实现,不能使用 PyTorch 或 TensorFlow 框架。


# 实验环境

Python3.10

Vs Code


# 实验准备

LeNet-5 是一个较简单的卷积神经网络。下图显示了其结构:输入的二维图像,先经过两次卷积层到池化层,再经过全连接层,最后使用 softmax 分类作为输出层。



### 卷积层

卷积层是卷积神经网络的核心基石。在图像识别里我们提到的卷积是二维卷积,即离散二维滤波器(也称作卷积核)与二维图像做卷积操作,简单的讲是二维滤波器滑动到二维图像上所有位置,并在每个位置上与该像素点及其领域像素点做内积。卷积操作被广泛应用与图像处理领域,不同卷积核可以提取不同的特征,例如边沿、线性、角等特征。在深层卷积神经网络中,通过卷积操作可以提取出图像低级到复杂的特征。




计算过程如上图示例。输入图像大小为 H=5, W=5, D=3, 这个示例图中包含两(用 K表示)组卷积核,即图中滤波器 W0 和 W1。

在卷积计算中,通常对不同的输入通道采用不同的卷积核,如图示例中每组卷积核包含(D=3)个 3×3(用 F×F 表示)大小的卷积核。另外,这个示例中卷积核在图像的水平方向(W 方向)和垂直方向(H 方向)的滑动步长为 2(用 S 表示);对输入图像周围各填充 1(用 P 表示)个 0,即图中输入层原始数据为蓝色部分,灰色部分是进行了大小为 1 的扩展,用 0 来进行扩展。经过卷积操作得到输出为 3×3×2(用 Ho×Wo×K 表示)大小的特征图,即 3×3 大小的 2 通道特征图,其中 Ho 计算公式为:Ho=(H-F+2×P)/S+1,Wo 同理。 而输出特征图中的每个像素,是每组滤波器与输入图像每个特征图的内积再求和,再加上偏置 bo,偏置通常对于每个输出特征图是共享的。输出特征图 o[::;0]中的最后一个-2 计算如上图右下角公式所示。


在卷积操作中卷积核是可学习的参数,经过上面示例介绍,每层卷积的参数大小为 D×F×F×K。卷积层的参数较少,这也是由卷积层的主要特性即局部连接和共享权重所决定。

## 池化层



池化是非线性下采样的一种形式,主要作用是通过减少网络的参数来减小计算量,并且能够在一定程度上控制过拟合。通常在卷积层的后面会加上一个池化层。池化包括最大池化、平均池化等。其中最大池化是用不重叠的矩形框将输入层分成不同的区域,对于每个矩形框的数取最大值作为输出层,如上图所示。

#### Lenet-5



LeNet-5 共有 7 层,不包含输入,每层都包含可训练参数;每个层有多个 Feature Map,每个 FeatureMap 通过一种卷积滤波器提取输入的一种特征,然后每个 FeatureMap 有多个神经元。

## INPUT 层-输入层

首先是数据 INPUT 层,输入图像的尺寸统一归一化为 32\*32。

### C1 层-卷积层

输入图片: 32\*32

卷积核大小:5\*5

卷积核种类: 6

输出 featuremap 大小: 28\*28 (32-5+1)=28

神经元数量: 28\*28\*6

可训练参数: (5\*5+1) \* 6(每个滤波器 5\*5=25 个 unit 参数和一个 bias 参数,一共 6 个滤波器)

连接数: (5\*5+1) \*6\*28\*28=122304

详细说明:对输入图像进行第一次卷积运算(使用 6 个大小为 5\*5 的卷积核),得到 6 个 C1 特征图(6 个大小为 28\*28 的 feature maps, 32-5+1=28)。我们再来看看需要多少个参数,卷积核的大小为 5\*5, 总共就有 6\*(5\*5+1)=156 个参数,其中+1 是表示一个核有一个 bias。 对于卷积层 C1,C1 内的每个像素都与输入图像中的 5\*5 个像素和 1 个 bias 有连接,所以总共有 156\*28\*28=122304 个连接(connection)。 有 122304 个连接,但是我们只需要学习 156 个参数,主要是通过权值共享实现的。

### S2 层-池化层(下采样层)

输入: 28\*28

采样区域: 2\*2

采样方式: 4个输入相加,乘以一个可训练参数,再加上一个可训练偏置。结果通过 sigmoid

采样种类: 6

输出 featureMap 大小: 14\*14(28/2)

神经元数量: 14\*14\*6

连接数: (2\*2+1) \*6\*14\*14

S2 中每个特征图的大小是 C1 中特征图大小的 1/4。

详细说明:第一次卷积之后紧接着就是池化运算,使用 2\*2 核 进行池化,于是得到了 S2,6 个 14\*14 的 特征图 (28/2=14)。S2 这个pooling 层是对 C1 中的 2\*2 区域内的像素求和乘以一个权值系数再加上一个偏置,然后将这个结果再做一次映射。同时有 5x14x14x6=5880个连接。

## C3 层-卷积层

输入: S2 中所有 6 个或者几个特征 map 组合

卷积核大小:5\*5

卷积核种类: 16

输出 featureMap 大小: 10\*10 (14-5+1)=10


C3 中的每个特征 map 是连接到 S2 中的所有 6 个或者几个特征 map 的,表示本层的特征 map 是上一层提取到的特征 map 的不同组合存在的一个方式是: C3 的前 6 个特征图以 S2 中 3 个相邻的特征图子集为输入。接下来 6 个特征图以 S2 中 4 个相邻特征图子集为输入。然后的 3 个以不相邻的 4 个特征图子集为输入。最后一个将 S2 中所有特征图为输入。

则:可训练参数: 6\*(3\*5\*5+1)+6\*(4\*5\*5+1)+3\*(4\*5\*5+1)+1\*(6\*5\*5+1) =1516


连接数: 10\*10\*1516=151600

详细说明:


第一次池化之后是第二次卷积,第二次卷积的输出是 C3,16 个 10x10 的特征图,卷积核大小是 5\*5. 我们知道 S2 有 6 个 14\*14 的 特征图,怎么从 6 个特征图得到 16 个特征图了?这里是通过对 S2 的特征图特殊组合计算得到的 16 个特征图。具体如下:



C3 的前 6 个 feature map (对应上图第一个红框的 6 列) 与 S2 层相连的 3 个 feature map 相连接(上图第一个红框),后面 6 个 feature map 与 S2 层相连的 4 个 feature map 相连接(上图第二个红框),后面 3 个 feature map 与 S2 层部分不相连的 4 个 feature map 相连接,最后一个与 S2 层的所有 feature map 相连。卷积核大小依然为 5\*5,所以总共有 6\*(3\*5\*5+1)+6\*(4\*5\*5+1)+3\*(4\*5\*5+1)+1\*(6\*5\*5+1)=1516 个参数。而图像大小为 10\*10,所以共有 151600 个连接。



C3与S2中前3个图相连的卷积结构如下图所示:



上图对应的参数为 3\*5\*5+1,一共进行 6 次卷积得到 6 个特征图, 所以有 6\*(3\*5\*5+1)参数。 为什么采用上述这样的组合了? 论文 中说有两个原因: 1)减少参数, 2)这种不对称的组合连接的方式有 利于提取多种组合特征。

## S4 层-池化层(下采样层)

输入: 10\*10

采样区域: 2\*2

采样方式: 4个输入相加,乘以一个可训练参数,再加上一个可训练

偏置。结果通过 sigmoid

采样种类: 16

输出 featureMap 大小: 5\*5 (10/2)

神经元数量: 5\*5\*16=400

连接数: 16\*(2\*2+1)\*5\*5=2000

S4 中每个特征图的大小是 C3 中特征图大小的 1/4

详细说明: S4 是 pooling 层,窗口大小仍然是 2\*2,共计 16 个 feature map, C3 层的 16 个 10x10 的图分别进行以 2x2 为单位的池化得到 16 个 5x5 的特征图。有 5x5x5x16=2000 个连接。连接的方式与 S2 层类似。

### C5 层-卷积层

输入: S4 层的全部 16 个单元特征 map (与 s4 全相连)


卷积核大小:5\*5

卷积核种类: 120

输出 featureMap 大小: 1\*1 (5-5+1)

可训练参数/连接: 120\*(16\*5\*5+1) =48120

详细说明: C5 层是一个卷积层。由于 S4 层的 16 个图的大小为 5x5, 与卷积核的大小相同, 所以卷积后形成的图的大小为 1x1。这里形成 120 个卷积结果。每个都与上一层的 16 个图相连。所以共有 (5x5x16+1)x120 = 48120 个参数,同样有 48120 个连接。C5 层的网络结构如下:



### F6 层-全连接层

输入: c5 120 维向量


计算方式: 计算输入向量和权重向量之间的点积,再加上一个偏置,结果通过 sigmoid 函数输出。

可训练参数:84\*(120+1)=10164

详细说明: 6 层是全连接层。F6 层有 84 个节点,对应于一个 7x12 的比特图, -1 表示白色, 1 表示黑色, 这样每个符号的比特图的黑白色就对应于一个编码。该层的训练参数和连接数是(120 + 1)x84=10164。ASCII 编码图如下:




F6 层的连接方式如下:



## Output 层-全连接层

Output 层也是全连接层,共有 10 个节点,分别代表数字 0 到 9,且如果节点 i 的值为 0,则网络识别的结果是数字 i。采用的是径向基函数(RBF)的网络连接方式。假设 x 是上一层的输入,y 是 RBF 的输出,则 RBF 输出的计算方式是:  $y_i = \sum_j (x_i - w_{ij})^2$ 

上式 w\_ij 的值由 i 的比特图编码确定, i 从 0 到 9, j 取值从 0 到 7\*12-1。RBF 输出的值越接近于 0, 则越接近于 i, 即越接近于 i 的 ASCII 编码图,表示当前网络输入的识别结果是字符 i。该层有 84x10=840 个参数和连接。



# 实验内容

#### Main

mian 函数中,首先是对数据的读取和正则化,由于 mnist 数据集中的图片为 28 \* 28, 需要 padding 到 32 \* 32。

然后,将处理之后的数据输入 train 函数,开始训练。

训练完成后,在测试集上测试训练网络的性能。

```
from data_processing import *
if __name__ == '__main__':
    train_images, train_labels, test_images, test_labels = load_data()
    print("Got data...\n")
    print("Normalization and zero-padding...\n")
    train_images = normalize(zero_pad(train_images[:, :, :, np.newaxis], 2), 'LeNet5')
    test_images = normalize(zero_pad(test_images[:, :, :, np.newaxis], 2),
print("The shape of training image with padding: ", train_images.shape)
    print("The shape of testing image with padding: ", test_images.shape)
    print("Finish data processing...\n")
    # train LeNet5
    LeNet5 = LeNet5()
    print("Start training...")
    start_time = time.time()
    train(LeNet5, train_images, train_labels)
    end_time = time.time()
    print("Finished training, the total training time is {}s \n".format(end_time - start_time))
    # read model
    print("Start testing...")
    error01, class_pred = LeNet5.Forward_Propagation(test_images, test_labels, 'test')
    print("error rate:", error01 / len(class_pred))
    print("Finished testing, the accuracy is {} \n".format(1 - error01 / len(class_pred)))
```

## 数据处理(data\_processing)

```
import numpy as np
data_dir = "D:/wtx/machine-learning/ex1/mnist_data/"
train_data_dir = "train-images-idx3-ubyte
train_label_dir = "train-labels-idx1-ubyte"
test_data_dir = "t10k-images-idx3-ubyte"
test_label_dir = "t10k-labels-idx1-ubyte"
def load_mnist(file_dir, is_images='True'):
    bin data = bin file.read()
    if is_images:
       # Read images
        fmt_header = '>iiii'
         magic, num_images, num_rows, num_cols = struct.unpack_from(fmt_header, bin_data, 0)
        data_size = num_images * num_rows * num_cols
mat_data = struct.unpack_from('>' + str(data_size) + 'B', bin_data, struct.calcsize(fmt_header))
        mat_data = np.reshape(mat_data, [num_images, num_rows, num_cols])
      # Read labels
fmt_header = '>ii'
        magic, num_images = struct.unpack_from(fmt_header, bin_data, 0)
        mat_data = struct.unpack_from('>' + str(num_images) + 'B', bin_data, struct.calcsize(fmt_header))
         mat_data = np.reshape(mat_data, [num_images])
    print('Load images from %s, number: %d, data shape: %s' % (file_dir, num_images, str(mat_data.shape)))
    return mat_data
```

```
# call the load_mnist function to get the images and labels of training set and testing set

def load_data():
    print('Loading MNIST data from files...')

train_images = load_mnist(os.path.join(data_dir, train_data_dir), True)

train_labels = load_mnist(os.path.join(data_dir, train_label_dir), False)

test_images = load_mnist(os.path.join(data_dir, test_data_dir), True)

test_labels = load_mnist(os.path.join(data_dir, test_label_dir), False)

return train_images, train_labels, test_images, test_labels

# transfer the image from gray to binary and get the one-hot style labels

def data_convert(x, y, m, k):

x[x <= 40] = 0
    x[x > 40] = 1
    ont_hot_y = np.zeros((m, k))

for t in range(m):
    ont_hot_y[t, y[t]] = 1
    return x, ont_hot_y
```

```
# padding for the matrix of images

def zero_pad(X, pad):

X_pad = np.pad(X, ((0, 0), (pad, pad), (0, 0)), 'constant', constant_values=(0, 0))

return X_pad

normalization of the input images

well and the image image, mode='LeNet5'):

image = image min()

image = image / image.max()

if mode == '0p1':

return image # range = [0,1]

elif mode == 'n1p1':

image = image * 2 - 1 # range = [-1,1]

image = image * 1.275 - 0.1 # range = [-0.1,1.175]

return image

return image

74
```

#### LeNet5

LeNet5 类的 Forward\_Propagation 和 Back\_Propagation 函数会调用每一层对应的 forward\_propagation 和 back\_propagation 函数,可以看到,层与层之间的参数会一层层的进行传递。通过 SDLM 算法进行计算得到的每一轮的学习率。

```
hyper_parameters_convolution = {"stride": 1, "pad": 0}
hyper_parameters_pooling = {"stride": 2, "f": 2}

self.C1 = ConvolutionLayer(kernal_shape["C1"], hyper_parameters_convolution)
self.a1 = Activation("LeNet5_squash")
self.S2 = PoolingLayer(hyper_parameters_pooling, "average")

self.C3 = ConvolutionLayer_maps(kernal_shape["C3"], hyper_parameters_convolution, C3_mapping)
self.a2 = Activation("LeNet5_squash")
self.S4 = PoolingLayer(hyper_parameters_pooling, "average")

self.C5 = ConvolutionLayer(kernal_shape["C5"], hyper_parameters_convolution)
self.a3 = Activation("LeNet5_squash")

self.F6 = FCLayer(kernal_shape["F6"])
self.a4 = Activation("LeNet5_squash")

self.Output = RBFLayer(bitmap)
```

```
def Forward_Propagation(self, input_image, input_label, mode):
    self.label = input_label
    self.Cl_FP = self.Cl.forward_propagation(input_image)
    self.al_FP = self.al.forward_propagation(self.Cl_FP)
    self.S2_FP = self.S2.forward_propagation(self.al_FP)

self.S2_FP = self.C3.forward_propagation(self.S2_FP)

self.a2_FP = self.a2.forward_propagation(self.C3_FP)

self.S4_FP = self.S4.forward_propagation(self.a2_FP)

self.S4_FP = self.C5.forward_propagation(self.S4_FP)

self.S4_FP = self.C5.forward_propagation(self.S4_FP)

self.a3_FP = self.a3.forward_propagation(self.S4_FP)

self.a4_FP = self.a5_FP[:, 0, 0, :]

self.f6_FP = self.f6.forward_propagation(self.flatten)

self.a4_FP = self.a4.forward_propagation(self.F6_FP)

# output sum of the loss over mini-batch when mode = 'train'
    # output tuple of (0/1 error, class_predict) when mode = 'test'

out = self.Output.forward_propagation(self.a4_FP, input_label, mode)

return out
```

```
def Back_Propagation(self, momentum, weight_decay):
              dy_pred = self.Output.back_propagation()
              dy pred = self.a4.back propagation(dy pred)
              F6_BP = self.F6.back_propagation(dy_pred, momentum, weight_decay)
              reverse_flatten = F6_BP[:, np.newaxis, np.newaxis, :]
              reverse_flatten = self.a3.back_propagation(reverse_flatten)
              C5_BP = self.C5.back_propagation(reverse_flatten, momentum, weight_decay)
              S4_BP = self.S4.back_propagation(C5_BP)
              S4_BP = self.a2.back_propagation(S4_BP)
              C3_BP = self.C3.back_propagation(S4_BP, momentum, weight_decay)
              S2_BP = self.S2.back_propagation(C3_BP)
              S2_BP = self.a1.back_propagation(S2_BP)
              C1_BP = self.C1.back_propagation(S2_BP, momentum, weight_decay)
        def SDLM(self, mu, lr_global):
    d2y_pred = self.Output.SDLM()
    d2y_pred = self.a4.SDLM(d2y_pred)
            F6_SDLM = self.F6.SDLM(d2y_pred, mu, lr_global)
            reverse_flatten = self.a3.SDLM(reverse_flatten)
            C5_SDLM = self.C5.SDLM(reverse_flatten, mu, lr_global)
            S4_SDLM = self.S4.SDLM(C5_SDLM)
02
03
            C3 SDLM = self.C3.SDLM(S4 SDLM, mu, lr global)
            S2_SDLM = self.S2.SDLM(C3_SDLM)
            S2_SDLM = self.a1.SDLM(S2_SDLM)
            C1_SDLM = self.C1.SDLM(S2_SDLM, mu, lr_global)
```

## 卷积层前向传播和后向传播(convolution\_utils)

```
def conv_forward(A_prev, W, b, hyper_parameters):
     Implements the forward propagation for a convolution function
     :param W: Weights, numpy array of shape (f, f, n_C_prev, n_C) :param b: Biases, numpy array of shape (1, 1, 1, n_C)
     :return: Z -- conv output, numpy array of shape (m, n_H, n_W, n_C)
cache -- cache of values needed for the conv_backward() function
    (m, n_H_prev, n_W_prev, n_C_prev) = A_prev.shape
(f, f, n_C_prev, n_C) = W.shape
     stride = hyper parameters["stride"]
    pad = hyper parameters["pad"]
    n_H = int((n_H_prev + 2 * pad - f) / stride + 1)
n_W = int((n_W_prev + 2 * pad - f) / stride + 1)
     Z = np.zeros((m, n_H, n_W, n_C))
     A_prev_pad = zero_pad(A_prev, pad)
     for h in range(n H): # loop over vertical axis of the output volume
          for w in range(n_W): # loop over horizontal axis of the output volume # Use the corners to define the (3D) slice of a_prev_pad.
               A_slice_prev = A_prev_pad[:, h * stride:h * stride + f, w * stride:w * stride + f, :]

# Convolve the (3D) slice with the correct filter W and bias b, to get back one output neuron.
               Z[:, h, w, :] = np.tensordot(A_slice_prev, W, axes=([1, 2, 3], [0, 1, 2])) + b
     assert (Z.shape == (m, n_H, n_W, n_C))
     cache = (A_prev, W, b, hyper_parameters)
```

```
# Numpy version: compute with np.dot

def conv_backward(dZ, cache):

"""

Implement the backward propagation for a convolution function

iparam dZ: gradient of the cost with respect to the output of the conv layer (Z), numpy array of shape (m, n_H, n_W, n_C)

iparam dZ: gradient of the cost with respect to the input of conv_forward()

:return: dA_prev -- gradient of the cost with respect to the input of the conv layer (A_prev),

numpy array of shape (m, n_H_prev, n_W_prev, n_C_prev)

dW -- gradient of the cost with respect to the weights of the conv layer (W)

numpy array of shape (f, f, n_C_prev, n_C)

db -- gradient of the cost with respect to the biases of the conv layer (b)

numpy array of shape (1, 1, 1, n_C)

(A_prev, W, b, hyper_parameters) = cache
(m, n_H_prev, n_W_prev, n_C_prev) = A_prev.shape
(f, f, n_C_prev, n_C) = A_prev.shape
(m, n_H, n_W, n_C) = A_prev.shape
(m,
```

```
for h in range(n_H): # loop over vertical axis of the output volume

for w in range(n_N): # loop over horizontal axis of the output volume

# Find the corners of the current "slice"

vert_start, horiz_start = h * stride, w * stride

vert_end, horiz_end = vert_start + f, horiz_start + f

# Use the corners to define the slice from a_prev_pad

A_slice = A_prev_pad[:, vert_start:vert_end, horiz_start:horiz_end, :]

# Update gradients for the window and the filter's parameters

dA_prev_pad[:, vert_start:vert_end, horiz_start:horiz_end, :] += np.transpose(np.dot(W, dZ[:, h, w, :].T), (3, 0, 1, 2))

dW += np.dot(np.transpose(A_slice, (1, 2, 3, 0)), dZ[:, h, w, :])

db += np.sum(dZ[:, h, w, :], axis=0)

# Set dA_prev to the unpadded dA_prev_pad

dA_prev = dA_prev_pad if pad == 0 else dA_prev_pad[:, pad:-pad, pad:-pad, :]

# Making sure your output shape is correct

assert (dA_prev.shape == (m, n_H_prev, n_W_prev, n_C_prev))

return dA_prev, dW, db
```

## 池化层前向传播和后向传播(pooling\_utils)

```
def pool_forward(A_prev, hyper_parameters, mode):
    m, n_H_prev, n_W_prev, n_C_prev = A_prev.shape
    f = hyper_parameters["stride"]

stride = hyper_parameters["stride"]

n_H = int(1 + (n_H_prev - f) / stride)
    n_W = int(1 + (n_W_prev - f) / stride)

n_C = n_C_prev

A = np.zeros((m, n_H, n_W, n_C))
    for h in range(n_H): # loop on the vertical axis of the output volume

for w in range(n_W): # loop on the horizontal axis of the output volume

# Use the corners to define the current slice on the ith training example of A_prev, channel c
    A_prev_slice = A_prev[:, h * stride:h * stride + f, w * stride:w * stride + f, :]

# Compute the pooling operation on the slice. Use an if statement to differentiate the modes.

if mode == "max":
    A[:, h, w, :] = np.max(A_prev_slice, axis=(1, 2))

elif mode == "average":
    A[:, h, w, :] = np.average(A_prev_slice, axis=(1, 2))

cache = (A_prev, hyper_parameters)
    assert (A.shape == (m, n_H, n_W, n_C))
    return A, cache
```

```
def subsampling_forward(A_prev, weight, b, hparameters):

A_, cache = pool_forward(A_prev, hparameters, 'average')

A = A_* weight + b

cache_A = (cache, A_)

return A, cache_A

def subsampling_backward(dA, weight, b, cache_A_):

(cache, A_) = cache_A

db = dA

dl = np.sum(np.multiply(dA, A_))

dA_ = dA * weight

dA_prev = pool_backward(dA_, cache, 'average')

return dA_prev, dW, db

return dA_prev, dW, db
```

## 训练 (train)

```
# train.py ?...
1  # coding=utf-8
2  import sys
3  import time
4  import math
5  import pickle
6  import numpy as np
7  import matplotlib.pyplot as plt
8
9
10  # Number of epochs & learning rate in the original paper
10  epochs_original, lr_global_original = 16, np.array([5e-4] * 2 + [2e-4] * 3 + [1e-4] * 3 + [5e-5] * 4 + [1e-5] * 8)
12  # Number of epochs & learning rate I used
13  epochs, lr_global_list = epochs_original, lr_global_original * 100
```

```
# return random-shoffled mini-batches

def random_mini_batches(image, label, mini_batch_size=256, one_batch=False):

m = image.shape[0] # number of training examples

mini_batches = []

# Shuffle (image, label)

permutation = list(np.random.permutation(m))

shuffled_image = image[permutation]

# extract only one batch

if one_batch:

mini_batch_image = shuffled_image[0: mini_batch_size, ;, ;]

mini_batch_label = shuffled_label[0: mini_batch_size]

return mini_batch_image, mini_batch_label

# Partition (shuffled_image, shuffled_y). Minus the end case.

num_complete_minibatches = math.floor(m / mini_batch_size)

for k in range(0, num_complete_minibatches):

mini_batch_label = shuffled_label[k * mini_batch_size * k * mini_batch_size * mini_batch_size, ;, ;, ]

mini_batch_label = shuffled_label[k * mini_batch_size * k * mini_batch_size * mini_batch_s
```

# 实验结果

## 加载数据集并进行处理

```
Loading MNIST data from files...
Load images from D:/wtx/machine-learning/ex1/mnist_data/train-images-idx3-ubyte, number: 60000, data shape: (60000, 28, 28)
Load images from D:/wtx/machine-learning/ex1/mnist_data/train-labels-idx1-ubyte, number: 60000, data shape: (60000,)
Load images from D:/wtx/machine-learning/ex1/mnist_data/t10k-images-idx3-ubyte, number: 10000, data shape: (10000, 28, 28)
Load images from D:/wtx/machine-learning/ex1/mnist_data/t10k-labels-idx1-ubyte, number: 10000, data shape: (10000, 36, 28)
Load images from D:/wtx/machine-learning/ex1/mnist_data/t10k-labels-idx1-ubyte, number: 10000, data shape: (10000,)
Got data...

Normalization and zero-padding...

The shape of training image with padding: (60000, 32, 32, 1)
The shape of testing image with padding: (10000, 32, 32, 1)
Finish data processing...
```

#### 训练模型

```
Start training...
            ------ epoch1 begin ------
global learning rate: 0.05
learning rates in trainable layers: [1.31954867e-05 1.22353197e-05 1.88510729e-05 1.94846469e-05]
batch size: 256
Done, cost of epoch 1: 670873.0466392617
0/1 error of training set: 3915 / 60000617
Time used: 291.01013588905334 sec
          ----- epoch1 end -----
                    ------ epoch2 begin ------
global learning rate: 0.05
learning rates in trainable layers: [2.40907961e-04 2.03305658e-05 1.65692959e-05 4.80155308e-06]
batch size: 256
Done, cost of epoch 2 : 220625.76046242146
0/1 error of training set: 1982 / 600002146
Time used: 313.1585421562195 sec
   ------ epoch2 end ------
```

#### 测试模型

正确率为 97.8%, 正确率较低的原因可能会训练模型时训练论述较低。但由于电脑配置较低, 在轮数较高时会因为系统内存不足导致整个程序卡死, 因此不得不降低轮数。(在只运行 vcode 的情况下, 每一轮中, 系统内存使用最高达到了 96%)